




图 2 类别数量与原始图像短边分布

2.3 近重复检测与分组切分

5. 为每张图计算 64 位 aHash 与 64 位 pHash；pHash 使用 32x32 灰度图的二维 DCT 低频 8x8 区域。
6. 对 identity、90/180/270 度旋转、水平翻转、垂直翻转六种变体分别计算哈希。
7. 同时比较整图与中心 60% 裁剪；两种尺度的 aHash 和 pHash 汉明距离都 ≤ 5 时才视为同一目标的近重复。
8. 用并查集把重复图连接成原子组；分层切分时整组进入训练集或验证集，禁止同组跨集合。
9. 每个类别至少保留 1 个验证样本，同时保证不会把一个类别全部分到验证集。