

$$L = \sum_i w_{(y_i)} \cdot CE_smooth(z_i, y_i) / \sum_i w_{(y_i)}$$

数值测试: $smoothing=0$ 时与标准加权 CE 的误差为 $1.19e-7$

5.2 优化与训练配置

表 2 统一训练配方

项目	配置	实现说明
优化器	AdamW [8]	backbone lr=1e-4; 新分类头 lr=1e-3
权重衰减	0.05	AdamW 解耦权重衰减
调度	5 epoch warmup + cosine	按 iteration 更新学习率
训练长度	60 epochs	最佳 checkpoint 按全类 MPC 选择
批量/精度	batch 32 + bf16	RTX 5090 D; bf16 不使用 GradScaler
稳定性	grad clip=1.0	降低异常梯度影响
复现	deterministic=True	Python/NumPy/Torch/CUDA RNG 均保存和恢复
断点续训	latest.pt 原子写入	模型、优化器、调度器、历史与随机状态完整恢复

5.3 为什么同时报告四个指标

- 17. **Overall top-1**: 所有验证图整体准确率，容易被数量多的头部类主导。
- 18. **Mean-per-class top-1 (MPC)** : 先算每类召回率再对类别平均，更关注尾部类。
- 19. **MPC (support>=5)**: 只统计验证支持至少 5 张的类别，隔离单样本尾类造成的跳变噪声。
- 20. **Macro-F1**: 每类 F1 再平均，同时惩罚“把其他类别误报成该类”的情况。

统计敏感性 验证支持为 1 的类别每多判对 1 张，全类 MPC 会跳 $1/42=2.38$ 个百分点。因此强方案必须把全类 MPC 与 support>=5 MPC 并列解读。